HITO 1 · SISTEMA INTELIGENTE DE PREDICCIÓN DEL CONSUMO ELÉCTRICO

Certamen 2 | Caso F: Energía | Prototipo académico

Integrantes: _____ | Fecha: noviembre de 2026

1. Problema industrial y objetivo

El consumo eléctrico de una instalación varía con la operación y el ambiente. Cuando se revisa solo al final del período, el encargado de mantenimiento puede detectar tarde aumentos inusuales. El objetivo es predecir el consumo horario y señalar posibles desviaciones, para priorizar inspecciones de equipos y horarios. Usuario: encargado de energía/mantenimiento. Decisión: revisar o no un aumento esperado; el sistema no desconecta equipos ni garantiza ahorros.

2. Datos y preparación

Variables: fecha-hora, energía consumida (kWh por hora), temperatura (°C), humedad (%) y jornada de operación. Se entregan tres series sintéticas horarias de 35 días cada una, con escenarios normal, alta demanda y pico. Son datos fabricados para probar software, no mediciones industriales. El código verifica columnas, tipos, fechas, faltantes, duplicados y consumos negativos; ordena temporalmente y crea hora, día, mes y rezagos. Para usarlo en una empresa hay que reemplazar los CSV por registros de medidores, documentar fuente, permisos, continuidad temporal y calibración.

3. Solución y arquitectura

Secuencia: disparador manual/programado en n8n → solicitud HTTP a API Python → limpieza y predicción → JSON de métricas y estado → LLM para explicación y recomendaciones → Gmail y Telegram → registro histórico. La API FastAPI y la plantilla JSON del flujo se incluyen. Para funcionar en una cuenta real hay que desplegar la API, configurar credenciales, destinatarios y registro persistente. El encargado valida mediciones antes de intervenir.

4. Modelo predictivo y evaluación

Se implementó RandomForestRegressor (250 árboles, profundidad máxima 12, semilla 42), que estima el consumo de la siguiente hora. Variables explicativas: clima, condición de jornada, hora, día, mes, rezagos de 1 y 24 horas y media móvil de 24 horas. La evaluación usa partición cronológica 80% entrenamiento / 20% prueba. La comparación simple es persistencia: la predicción de la próxima hora es igual al consumo de la hora actual. Se calculan MAE y RMSE en kWh; cuanto menores, mejor. Esta prueba de una sola partición no reemplaza validación temporal múltiple con datos reales.

5. Interpretación LLM y reglas de decisión

Python genera el JSON numérico, incluyendo estado NORMAL/ALERTA. El umbral ilustrativo marca ALERTA si el promedio de predicciones supera 115% del histórico o su percentil 95 supera 135%. El LLM recibe solo ese JSON y responde con resumen, hallazgos, acciones, validación humana y limitación, sin inventar valores. El prompt está en prompt_llm.txt. La integración debe validar el JSON antes de notificar; el responsable debe comprobar medidor, horarios y cargas críticas.

6. Pruebas locales y resultados

Se ejecutaron tres escenarios distintos desde Python. Los JSON individuales quedan en resultados/ y pueden reproducirse con los comandos del README. Los valores son exclusivamente demostrativos. No se ejecutaron los envíos de Gmail o Telegram ni la llamada real al LLM; esos componentes requieren credenciales y un entorno n8n conectado.

Escenario	Estado	MAE RF	MAE base	RMSE RF	RMSE base
1 normal	ALERTA	1.269	2.177	1.545	3.352
2 alta demanda	ALERTA	1.228	2.723	1.52	4.36
3 pico consumo	ALERTA	2.419	2.886	6.53	5.253

7. Limitaciones, evidencias y siguientes pasos

Limitaciones: datos sintéticos, umbrales sin calibración operacional, un único corte temporal, modelo no probado en instalaciones reales. Para completar la evidencia de Hito 1: (a) ejecutar el flujo n8n con tres entradas, (b) capturar las tres ejecuciones, (c) adjuntar correos Gmail y mensajes Telegram efectivamente recibidos, (d) guardar historial y (e) verificar salida JSON del LLM. No se debe presentar la plantilla como automatización ya operativa.

Conclusión: el prototipo demuestra procesamiento, evaluación predictiva y estructura de integración para apoyar la gestión energética. Su adopción exige validación con datos reales y supervisión humana. Uso de IA: se empleó asistencia de IA para la preparación del proyecto; las recomendaciones automáticas futuras requieren un servicio LLM configurado y revisión del equipo.

Fuentes técnicas: documentación oficial de scikit-learn (RandomForestRegressor, métricas de regresión), pandas (series temporales), FastAPI y n8n. Datos del prototipo: simulados, generados específicamente para esta demostración.